

Lecture3

贝叶斯分类

贝叶斯分类（统计决策）

- 贝叶斯公式
- 最小错误率贝叶斯决策
- 最小风险贝叶斯决策
- 习题

- 给一个硬币，已知重量 x ，猜是5角还是1角

- 后验概率 (posterior probability)

$$P(\omega_i|x)$$

- 决策规则

$$x \begin{cases} \in \omega_1 & P(\omega_1|x) \geq P(\omega_2|x) \\ \in \omega_2 & P(\omega_1|x) < P(\omega_2|x) \end{cases}$$

- 错误率

$$P(\text{error}|x) = 1 - P(\omega_1|x) = P(\omega_2|x) \quad (\text{如果决策 } x \in \omega_1)$$

- 贝叶斯公式 (Bayes formula)

$$P(\omega_i|x) = \frac{P(\omega_i, x)}{P(x)} = \frac{P(x|\omega_i)P(\omega_i)}{P(x)}$$

The diagram illustrates Bayes' theorem with the following components and annotations:

- Posterior Probability:** $p(y|x)$ (indicated by a blue arrow pointing to the left side of the equation)
- Likelihood:** $p(x|y)$ (indicated by a blue arrow pointing to the numerator term $p(x|y)$)
- Class Prior Probability:** $p(y)$ (indicated by a blue arrow pointing to the numerator term $p(y)$)
- Predictor Prior Probability:** $p(x)$ (indicated by a blue arrow pointing to the denominator term $p(x)$)

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)}$$

The diagram shows the equation for Bayes' theorem: $p(y|x) = \frac{p(x|y)p(y)}{p(x)}$. Red boxes highlight the posterior probability $p(y|x)$ and the likelihood $p(x|y)$. Blue arrows point from labels to the corresponding terms: 'Likelihood' points to $p(x|y)$, 'Class Prior Probability' points to $p(y)$, 'Posterior Probability' points to $p(y|x)$, and 'Predictor Prior Probability' points to $p(x)$.

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)}$$

Likelihood

Class Prior Probability

Posterior Probability

Predictor Prior Probability

似然函数 $p(x|y)$ ：根据样本出现的频率来估计样本特征的概率

后验概率 $p(y|x)$ ：事件 x 发生后或给定样本 x ，得到结果或判定类别 y 的概率

概率 vs 似然

概率(Probability)：已知样本属性或特征，推测样本属于各种类别的可能性


似然(Likelihood)：样本属性或特征未知时，给定样本类别去推测样本的可能属性或特征

最小错误率贝叶斯决策

样本 x 上错误的概率 $P(\text{error}|x) = \begin{cases} P(\omega_2|x) & \text{if } x \in \omega_1 \\ P(\omega_1|x) & \text{if } x \in \omega_2 \end{cases}$

所有服从同样分布的独立样本上错误概率的期望

$$P(\text{error}) = \int P(\text{error}|x)P(x)dx$$



决策规则 如果 $P(\omega_1|x) > P(\omega_2|x)$ ，则 $x \in \omega_1$ ；反之，则 $x \in \omega_2$

两类错误率

预测类别	真实类别	
	Positive	Negative
Positive	TP	FP
Negative	FN	TN

灵敏度 $S_n = \frac{TP}{TP+FN}$

特异度 $S_p = \frac{TN}{TN+FP}$

- P(Positive)和N(Negative) 表示模型的判断结果
- T(True)和F(False) 表示模型的判断结果是否正确
- FP: 假正例（第一类错误）
- FN: 假负例（第二类错误）
- TP: 真正例
- TN: 真负例

两类错误率

- 第一类错误率 α ：真实的阴性样本中被错误判断为阳性的比例
- 第二类错误率 β ：真实的阳性样本中被错误判断为阴性的比例


第一类错误率： $P_1(e) = \int_{R_2} p(x | \omega_1) dx$

第二类错误率： $P_2(e) = \int_{R_1} p(x | \omega_2) dx$

Neyman-Pearson决策

固定一类错误率、使另一类错误率尽可能小

$$\begin{aligned} &\min P_1(e) \\ &s.t. P_2(e) - \varepsilon_0 = 0 \end{aligned}$$



ROC(receiver operating characteristic curve)曲线


对同一数据集在**不同判定标准**(阈值)下的结果

分类问题: 判断是否为汉堡🍔的图片


$$TPR = \frac{TP}{TP + FN} = \frac{0}{0 + 4} = 0$$
$$FPR = \frac{FP}{FP + TN} = \frac{0}{0 + 4} = 0$$

预测类别

真实类别		是🍔	不是🍔
预测类别	是🍔	0	0
	不是🍔	4	4



阈值: (0.9, 1]



- ROC曲线能容易查出任意界限值对性能的识别能力
- ROC曲线越靠近左上角, 试验的准确率越高

最小风险贝叶斯决策

条件风险（期望损失）：
$$R(c_i|x) = \sum_{j=1}^N k_{ij} P(c_j|x)$$

1. 错误的分类会带来损失

把病人误诊为健康 ---> 风险代价大

把正常人误诊为病人 ---> 风险代价小

2. 不同的错误带来的损失可能不同, 记作 $k_{ij} \begin{cases} i \rightarrow \text{判断类别} \\ j \rightarrow \text{真实类别} \end{cases}$

举例： $c = 1, 2, 3, 4$

$$R(c_1|x) = k_{1,1}P(c_1|x) + k_{1,2}P(c_2|x) + k_{1,3}P(c_3|x) + k_{1,4}P(c_4|x)$$

最小风险贝叶斯决策

判定准则：

总体风险： 最小化条件风险的期望

$$R(h) = E_x[R(h(x)|x)] \longleftarrow \text{最小化}$$

最小化每一项 $R(c|x)$

$$h^*(x) = \arg \min_{c \in Y} R(c|x) = \sum k_{ij} P(c|x)$$

贝叶斯最优分类器

最小风险贝叶斯决策

0-1损失: $k_{ij} = \begin{cases} 0, & \text{if } i=j \\ 1, & \text{otherwise} \end{cases}$

$$h^*(x) = \arg \min_{c \in Y} R(c | x)$$



$$R(c | x) = 1 - p(c | x)$$

$$R(c|x) = k_{1,1}P(c_1 | x) + k_{1,2}P(c_2 | x) + k_{1,3}P(c_3 | x) + k_{1,4}P(c_4 | x)$$

$$h^*(x) = \arg \max_{c \in Y} P(c | x)$$

练习

(1) 假设在某个局部地区细胞识别中正常 (ω_1) 和异常 (ω_2) 两类的先验概率分别为：正常状态 $P(\omega_1) = 0.9$ ，异常状态 $P(\omega_2) = 0.1$ 。

现有一待识别的细胞，其观察值为 x ，从类条件概率密度曲线上分别查得 $P(x|\omega_1) = 0.2$ ， $P(x|\omega_2) = 0.4$ ，试对该细胞 x 进行分类。

(2) 在 (1) 给出条件的基础上，利用如下决策表，按**最小风险贝叶斯决策**进行分类。

决策	状态	
	ω_1	ω_2
α_1	0	6
α_2	1	0

解1: 利用贝叶斯公式, 分别计算 ω_1 及 ω_2 的后验概率

$$P(\omega_1 | x) = \frac{p(x | \omega_1)P(\omega_1)}{\sum_{j=1}^2 p(x | \omega_j)P(\omega_j)} = \frac{0.2 * 0.9}{0.2 * 0.9 + 0.4 * 0.1} = 0.818$$

$$P(\omega_2 | x) = 1 - P(\omega_1 | x) = 0.182$$

根据贝叶斯决策规则式 如果 $P(\omega_1 | x) > P(\omega_2 | x)$, 则 $x \in \omega_1$, 因为

$$P(\omega_1 | x) = 0.818 > P(\omega_2 | x) = 0.182$$

所以合理的决策是把 x 归类于正常状态 (ω_1)

解2：已知条件为

$$P(\omega_1)=0.9, \quad P(\omega_2)=0.1 \qquad \lambda_{11} = 0, \quad \lambda_{12} = 6$$

$$P(x|\omega_1)=0.2, \quad P(x|\omega_2)=0.4 \qquad \lambda_{21} = 1, \quad \lambda_{22} = 0$$

根据解1的计算结果可知后验概率为： $P(\omega_1 | x) = 0.818, \quad P(\omega_2 | x) = 0.182$

再按式 $R(\alpha_i | x) = \sum_{j=1}^c \lambda(\alpha_i | \omega_j) P(\omega_j | x)$ 计算条件风险：

$$R(\alpha_1 | x) = \sum_{j=1}^2 \lambda_{1j} P(\omega_j | x) = \lambda_{12} P(\omega_2 | x) = 1.092$$

$$R(\alpha_2 | x) = \lambda_{21} P(\omega_1 | x) = 0.818$$

$$R(\alpha_1 | x) > R(\alpha_2 | x)$$

可知决策 ω_2 的条件风险小于决策为 ω_1 的条件风险, 因此采取决策行动 α_2 , 即判断待识别的细胞 x 为 ω_2 类—异常细胞。


贝叶斯分类（参数估计）

- 最大似然估计
- 最大后验估计
- 贝叶斯估计

最大似然估计

原理：通过给定的观测数据，猜测模型参数情况

- 相信实验/观测数据反映的客观规律
- 实验结果/数据既然已经存在或发生，说明事件发生是大概率事件



最大似然估计求解——抛硬币问题


6次实验结果(每次抛10枚, 统计“花”的次数): $x_1, x_2, \dots, x_6 = \{5, 4, 6, 5, 2, 4\}$

$$L(\theta) = [C_{10}^5 \theta^5 (1-\theta)^5] [C_{10}^4 \theta^4 (1-\theta)^6] \dots$$

最大似然函数步骤:

- 写似然函数 $L(\theta)$
- 取对数 $\ln L(\theta)$
- 求偏导 $\frac{\partial \ln L(\theta)}{\partial \theta} = 0$

$$\hat{\theta} \longrightarrow \max L(\theta)$$



估计抛一次硬币“花”的概率为0.43

正态分布下的最大似然估计

概率密度函数 $f(x) = \frac{1}{\sqrt{2\pi}\delta} e^{-\frac{(x-\mu)^2}{2\delta^2}}$

写似然函数 $L(\mu, \delta^2) = \prod_{i=1}^N f(x_i | \theta) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi}\delta} e^{-\frac{(x_i-\mu)^2}{2\delta^2}} = (2\pi\delta^2)^{-\frac{n}{2}} e^{-\frac{1}{2\delta^2} \sum_{i=1}^n (x_i-\mu)^2}$

取对数 $\ln L(u, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - u)^2$

求偏导 $\left\{ \begin{array}{l} \frac{\partial \ln L(u, \sigma^2)}{\partial u} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - u) = 0 \\ \frac{\partial \ln L(u, \sigma^2)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - u)^2 = 0 \end{array} \right. \longrightarrow \left\{ \begin{array}{l} u^* = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \\ \sigma^{*2} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \end{array} \right.$

最大后验估计MAP

最大后验估计与最大似然估计相似

不同点：在于估计 θ 的函数中允许加入一个先验 $p(\theta)$ ，此时不是要求似然函数最大，而是要求由贝叶斯公式计算出的整个后验概率最大

$$\begin{aligned}\hat{\theta}_{MAP} &= \arg \max \frac{p(X | \theta) p(\theta)}{p(X)} \\ &= \arg \max p(X | \theta) p(\theta) \\ &= \arg \max \{L(\theta | X) + \log p(\theta)\} \\ &= \arg \max \left\{ \sum_{x \in X} p(\theta | X) + \log p(\theta) \right\}\end{aligned}$$

贝叶斯估计 (Bayesian Estimation)

- 基本思想

- ✓ 把参数估计看成贝叶斯决策问题
- ✓ 待估计参数看成具有先验分布 $p(\theta)$ 的随机变量
- ✓ 其取值和样本集有关 $\chi = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$
- ✓ 最优条件是最小化错误率或者风险, 损失函数为 $\lambda(\hat{\theta}, \theta)$

- 用 $\hat{\theta}$ 来估计时的总期望风险为

样本取值空间 E^d , 参数取值空间为 Θ

$$R = \int_{E^d} \int_{\Theta} \lambda(\hat{\theta}, \theta) p(\theta|\mathbf{x}) p(\mathbf{x}) d\theta d\mathbf{x}$$

贝叶斯估计

$p(\theta)$ 是待估计参数 θ 的先验概率, θ 取值与样本集 $D = \{x_1, x_2, \dots, x_N\}$ 有关, $\lambda(\hat{\theta}, \theta)$ 是 $\hat{\theta}$ 作为 θ 的估计量时的损失函数。

定义条件风险函数为

$$R(\hat{\theta} | x) = \int \lambda(\hat{\theta}, \theta) p(\theta | x) d\theta$$

则有:

$$R = \int_{E^d} R(\hat{\theta} | x) p(x) dx$$

又因 $R(\hat{\theta} | x)$ 非负, 则由贝叶斯决策知, 求R最小即求 $R(\hat{\theta} | x)$ 最小, 即:

$$\theta^* = \arg \min R(\hat{\theta} | x)$$

可得最优估计: $\theta^* = \int \theta p(\theta | x) d\theta$

贝叶斯估计步骤

贝叶斯估计的基本步骤(基于平方误差损失函数):

1、确定参数 θ 的先验分布 $P(\theta)$

2、由样本集 $D = \{x_1, x_2, \dots, x_n\}$ 求出样本联合分布 $P(D|\theta)$,

其中:
$$P(D|\theta) = \prod_{n=1}^N P(x_n|\theta)$$

3、利用贝叶斯公式, 求后验分布
$$P(\theta|D) = \frac{P(D|\theta)P(\theta)}{\int_{\theta} P(D|\theta)P(\theta)d\theta}$$


4、求出贝叶斯估计值
$$\hat{\theta} = \int_{\theta} \theta P(\theta|D)d\theta$$

作业二：利用贝叶斯分类器实现基于身高体重的性别分类

- 推荐编程环境：Anaconda+Jupyter notebook+pytorch

安装教程：[点这](#)

- 要求可视化决策面以及分类结果



Sources

- <https://www.youtube.com/watch?v=60pqgfT5tZM>
Text Classification Using Naive Bayes | Simplilearn 20mins
- <https://www.youtube.com/watch?v=O2L2Uv9pdDA>
Naive Bayes, Clearly Explained!!! 15mins
- <https://www.youtube.com/watch?v=9wCnvr7Xw4E>
Bayes' Theorem, Clearly Explained!!!! 14mins
- <https://www.youtube.com/watch?v=XQoLVl31ZfQ>
Bayes' Theorem - The Simplest Case 5mins