

Lecture6

集成学习

主要内容


01 个体与集成

02 Boosting、Bagging 随机森林

03 结合策略

04 多样性

集成学习 (Ensemble learning) : 构建并结合**多个学习器**完成学习任务, 也被称为多分类器系统



集成学习目的：学习分类器 $H(x)$, $H(x) = h_1(x) + h_2(x) + \dots + h_m(x)$

- 个体学习器具有一定准确率
- 各个学习器间要有差异

好而不同

	测试例1	测试例2	测试例3
h_1	✓	✓	×
h_2	×	✓	✓
h_3	✓	×	✓
集成	✓	✓	✓

(a) 集成提升性能

	测试例1	测试例2	测试例3
h_1	✓	✓	×
h_2	✓	✓	×
h_3	✓	✓	×
集成	✓	✓	×

(b) 集成不起作用

各学习器之间无差异

	测试例1	测试例2	测试例3
h_1	✓	×	×
h_2	×	✓	×
h_3	×	×	✓
集成	×	×	×

(c) 集成起负作用

学习器本身准确率低

考虑二分类问题，假设基分类器的错误率为：

$$P(h_i(x) \neq f(x)) = \varepsilon$$

假设通过简单投票法结合 T 个基分类器，若有超过半数正确，则集成分类正确：

$$H(x) = \text{sign}\left(\sum_{i=1}^T h_i(x)\right)$$

假设基分类器的错误率**相互独立**，则由Hoeffding不等式可知，集成错误率为

$$P(H(x) \neq f(x)) = \sum_{k=0}^{\lfloor T/2 \rfloor} \binom{T}{k} (1-\varepsilon)^k \varepsilon^{T-k} \leq e^{-\frac{1}{2}T(1-2\varepsilon)^2}$$

由上式可知随个体分类器增多，分类错误率呈指数级下降

Example: Weather Forecast

Reality							
1							
2							
3							
4							
5							
Combine							

个体分类器 $h(x)$ 准确率不高，集成后的分类器 $H(x)$ 准确率上升

根据个体学习器的生成方式，集成学习方法可分为两大类：

- 个体学习器间存在强依赖关系、必须**串行生成**的序列化方法
 - **Boosting**
- 个体学习器间不存在强依赖关系、可**同时生成**的并行化方法
 - **Bagging**
 - **随机森林 (Random Forest)**

主要内容

01 个体与集成

02 Boost、Bagging & 随机森林

03 结合策略

04 多样性

Boosting-Adaboost

Adaboost算法采用调整样本权重的方式:

- 提高**错误分类样本的权重**，降低**正确分类样本的权重**
- 采用**加权多数表决法**，加大分类误差率小的分类器权值，减小分类误差率大的分类器权值

输入: 训练集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;
基学习算法 $\mathcal{L}$;
训练轮数 T .

过程:

```
1:  $\mathcal{D}_1(\mathbf{x}) = 1/m$ .  
2: for  $t = 1, 2, \dots, T$  do  
3:    $h_t = \mathcal{L}(D, \mathcal{D}_t)$ ;  
4:    $\epsilon_t = P_{\mathbf{x} \sim \mathcal{D}_t}(h_t(\mathbf{x}) \neq f(\mathbf{x}))$ ;  
5:   if  $\epsilon_t > 0.5$  then break  
6:    $\alpha_t = \frac{1}{2} \ln \left( \frac{1-\epsilon_t}{\epsilon_t} \right)$ ;  
7:    $\mathcal{D}_{t+1}(\mathbf{x}) = \frac{\mathcal{D}_t(\mathbf{x})}{Z_t} \times \begin{cases} \exp(-\alpha_t), & \text{if } h_t(\mathbf{x}) = f(\mathbf{x}) \\ \exp(\alpha_t), & \text{if } h_t(\mathbf{x}) \neq f(\mathbf{x}) \end{cases}$   
       $= \frac{\mathcal{D}_t(\mathbf{x}) \exp(-\alpha_t f(\mathbf{x}) h_t(\mathbf{x}))}{Z_t}$   
8: end for
```

输出: $H(\mathbf{x}) = \text{sign} \left(\sum_{t=1}^T \alpha_t h_t(\mathbf{x}) \right)$

Adaboost算法流程图

例题：使用Adaboost构建分类器，对下列10个样本进行分类。x为样本值，y为对应x的标记， $y \in \{-1, 1\}$

x	0	1	2	3	4	5	6	7	8	9
y	1	1	1	-1	-1	-1	1	1	1	-1
w_1 (初始权重)	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1

初始数据权重 $D_1 = (w_{11}, w_{12}, \dots, w_{110}) = (0.1, 0.1, 0.1, 0.1, 0.1, 0.1, 0.1, 0.1, 0.1, 0.1)$

①对第一个分类器 $h_1(x)$ ，阈值取2.5时，分类错误数据权重和最小

$$h_1(x) = \begin{cases} 1, & x < 2.5 \\ -1, & x > 2.5 \end{cases}$$

② $h_1(x)$ 分类误差率 $e_1 = \sum_{i=0}^9 w_i I(h_1(x_i) \neq y_i) = 3 \times 0.1 = 0.3$

x	0	1	2	3	4	5	6	7	8	9
y	1	1	1	-1	-1	-1	1	1	1	-1
w ₂	0.0715	0.0715	0.0715	0.0715	0.0715	0.0715	0.1666	0.1666	0.1666	0.0715

③计算 $h_1(x)$ 的系数: $\alpha_1 = \frac{1}{2} \ln \frac{1-e_1}{e_1} = 0.4236$

$$z_i = 2\sqrt{e_i(1-e_i)}$$

④更新数据的权重: $D_2 = (w_{21}, w_{22}, \dots, w_{210})$ $w_{2i} = \frac{w_{1i}}{Z_1} e^{-\alpha_1 y_i h_1(x_i)}, i = 1, 2, \dots, 10$

$$D_2 = (0.0715, 0.0715, 0.0715, 0.0715, 0.0715, 0.0715, 0.1666, 0.1666, 0.1666, 0.0715)$$

$$f_1(x) = 0.4236h_1(x)$$

$$H(x) = \text{sign}(f_1(x)) = \text{sign}(0.4236h_1(x))$$

$H(x)$ 分类错误三个数据, 对应 x 的值为6, 7, 8

x	0	1	2	3	4	5	6	7	8	9
y	1	1	1	-1	-1	-1	1	1	1	-1
w_2	0.0715	0.0715	0.0715	0.0715	0.0715	0.0715	0.1666	0.1666	0.1666	0.0715

①对于第二个分类器 $h_2(x)$, 阈值取8.5, 分类错误数据权重和最小 $h_2(x) = \begin{cases} 1, & x < 8.5 \\ -1, & x > 8.5 \end{cases}$

② $h_2(x)$ 分类误差率 $e_2 = \sum_{i=0}^9 w_i I(h_2(x_i) \neq y_i) = 3 \times 0.0715 = 0.2145$

③计算 $h_2(x)$ 的系数: $\alpha_2 = \frac{1}{2} \ln \frac{1-e_2}{e_2} = 0.6490$

x	0	1	2	3	4	5	6	7	8	9
y	1	1	1	-1	-1	-1	1	1	1	-1
w_2	0.0715	0.0715	0.0715	0.0715	0.0715	0.0715	0.1666	0.1666	0.1666	0.0715
w_3	0.0455	0.0455	0.0455	0.1666	0.1666	0.1666	0.1060	0.1060	0.1060	0.0455

④更新数据权重: $w_{3i} = \frac{w_{2i}}{Z_2} e^{-\alpha_2 y_i h_2(x_i)}, i = 1, 2, \dots, 10$

$$D_3 = (0.0455, 0.0455, 0.0455, 0.1667, 0.1667, 0.1667, 0.1060, 0.1060, 0.1060, 0.0455)$$

$$f_2(x) = 0.4236h_1(x) + 0.6490h_2(x)$$

$$H(x) = \text{sign}(f_2(x)) = \text{sign}(0.4236h_1(x) + 0.6490h_2(x))$$

$H(x)$ 分类错误三个数据, 对应序号3, 4, 5

x	0	1	2	3	4	5	6	7	8	9
y	1	1	1	-1	-1	-1	1	1	1	-1
w_3	0.0455	0.0455	0.0455	0.1666	0.1666	0.1666	0.1060	0.1060	0.1060	0.0455

①对于第三个分类器 $h_3(x)$, 阈值取5.5, 分类错误数据权重和最小 $h_3(x) = \begin{cases} 1, & x > 5.5 \\ -1, & x < 5.5 \end{cases}$

② $h_3(x)$ 在训练集误差率 $e_3 = \sum_{i=0}^9 w_i I(h_3(x_i) \neq y_i) = 4 \times 0.0455 = 0.1820$

③计算 $h_3(x)$ 的系数: $\alpha_3 = \frac{1}{2} \ln \frac{1-e_3}{e_3} = 0.7514$

x	0	1	2	3	4	5	6	7	8	9
y	1	1	1	-1	-1	-1	1	1	1	-1
w_3	0.0455	0.0455	0.0455	0.1666	0.1666	0.1666	0.1060	0.1060	0.1060	0.0455
w_4	0.1250	0.1250	0.1250	0.1018	0.1018	0.1018	0.0647	0.0647	0.0647	0.1250

④更新数据的权重：

$$D_4 = (0.1250, 0.1250, 0.1250, 0.1018, 0.1018, 0.1018, 0.0647, 0.0647, 0.0647, 0.1250)$$


$$f_3(x) = 0.4236h_1(x) + 0.6490h_2(x) + 0.7514h_3(x)$$

$$H(x) = \text{sign}(f_3(x)) = \text{sign}(0.4236h_1(x) + 0.6490h_2(x) + 0.7514h_3(x))$$

$H(x)$ 分类全部正确

Bagging与随机森林

Bagging基于自助采样法采样 m 个含 n 个训练样本的采样集，然后基于每个采样集训练一个基学习器，再将这些基学习器进行结合；结合策略有采样法、平均法等。



Bagging算法

Bagging算法特点:

- 时间复杂度低
- 可使用包外估计

输入: 训练集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;
基学习算法 $\mathcal{L}$;
训练轮数 T .

过程:

```
1: for  $t = 1, 2, \dots, T$  do  
2:    $h_t = \mathcal{L}(D, \mathcal{D}_{bs})$   
3: end for
```

输出: $H(\mathbf{x}) = \arg \max_{y \in \mathcal{Y}} \sum_{t=1}^T \mathbb{I}(h_t(\mathbf{x}) = y)$

Bagging算法流程图

Bagging算法-包外估计

$H^{oob}(x)$ 表示对样本 x 的包外预测，即仅考虑未使用样本 x 训练的基学习器在 x 上的预测


$$H^{oob}(x) = \arg \max \sum_{t=1}^T I(h_t(x) = y) * I(x \notin D_t)$$

Bagging泛化误差的包外估计为：

$$\varepsilon^{oob} = \frac{1}{|D|} \sum_{(x,y) \in D} I(H^{oob}(x) \neq y)$$

随机森林

随机森林 (Random Forest, 简称RF) 是Bagging的一个扩展变体，以**决策树**为基学习器构建Bagging集成的基础上，进一步在决策树训练过程中引入随机属性选择




随机森林算法

- ① 从数据集中随机选择 k 个特征，共 m 个特征（其中 $k \ll m$ ），据此建立决策树
- ② 重复 n 次，这 k 个特性经过不同随机组合建立起来 n 棵决策树
- ③ 对每个决策树都传递随机变量来预测结果
- ④ 将票数最高的预测目标作为随机森林算法的最终预测

随机森林算法特点：

- 可处理高维数据，**不用特征选择**
- 易**并行化**，速度快
- 可视化展示，便于分析



主要内容

01 个体与集成


02 Boost、Bagging & 随机森林

03 结合策略

04 多样性

结合策略

- 从统计方面，降低因单一学习器误选导致的泛化性能不佳的风险
- 从计算方面，减低陷入糟糕局部极小点的风险
- 从表示方面，扩大假设空间，可能学得更好的近似



结合策略-平均法

对数值型输出 $h_i(x) \in \mathbb{R}$, 最常见的结合策略是使用**平均法** (averaging)

平均法分为：简单平均法、加权平均法

假定集成包含 T 个基学习器 $\{h_1, h_2, \dots, h_T\}$, 其中 h_i 在示例 x 上的输出为 $h_i(x)$

- 简单平均法

$$H(\mathbf{x}) = \frac{1}{T} \sum_{i=1}^T h_i(\mathbf{x})$$

- 加权平均法

$$H(\mathbf{x}) = \frac{1}{T} \sum_{i=1}^T h_i(\mathbf{x})$$

其中 w_i 为个体学习器权重，通常要求 $H(x) = \sum_{i=1}^T w_i h_i(x)$

结合策略-投票法

投票法常用于分类任务, 学习器 h 将从类别标记集合 $\{c_1, c_2, \dots, c_N\}$ 中预测一个标记

投票法分为: **绝对多数投票法**、**相对多数投票法**、**加权投票法**

将 h_i 在样本 x 上的预测输出表示为一个 N 维向量 $(h_i^1(x); h_i^2(x); \dots; h_i^N(x))$, 其中 $h_i^j(x)$ 是 h_i 在类别标记 c_j 上的输出

- 绝对多数投票法

$$H(\mathbf{x}) = \begin{cases} c_j, & \text{if } \sum_{i=1}^T h_i^j(\mathbf{x}) > 0.5 \sum_{k=1}^N \sum_{i=1}^T h_i^k(\mathbf{x}) \\ \text{reject}, & \text{otherwise.} \end{cases}$$

要求票数超过一半


- 相对多数投票法 $H(\mathbf{x}) = c_{\arg \max_j \sum_{i=1}^T h_i^j(\mathbf{x})}$

- 加权投票法 $H(\mathbf{x}) = c_{\arg \max_j \sum_{i=1}^T w_i h_i^j(\mathbf{x})}$
 $w_i \geq 0, \sum_{i=1}^T w_i = 1$

结合策略-学习法

*Stacking*为学习法典型代表，在*Stacking*中：

- 个体学习器称为**初级学习器**
- 用于结合的学习器为**次级学习器**



Stacking学习法

Stacking 先**从初始数据集**训练出**初级学习器**，然后“生成”一个新数据集用于训练**次级学习器**。在新数据集中，**初级学习器的输出作为输入特征**，而初始样本的标记仍被当作**样例标记**。

小结

- 学习器结合的优点：增强泛化性能、避免局部极小、扩大假设空间
- 结合策略分三种：
 - ✓ 对基学习器结果进行加权平均
 - ✓ 对基学习器结果进行加权计数投票
 - ✓ 将预测模型分为两层：第二层学习器以第一层的结果进行训练

主要内容

01 个体与集成

02 Boost、Bagging & 随机森林

03 结合策略

04 多样性

多样性-误差分歧分解

假设用个体学习器 $h_1, h_2, \dots, h_T$ 通过加权平均法结合产生的集成来完成回归学习任务

$f: \mathbb{R}^d \rightarrow \mathbb{R}$ 对示例 x , 定义学习器 h_i 的 “分歧” (ambiguity) 为

$$A(h_i | \mathbf{x}) = (h_i(\mathbf{x}) - H(\mathbf{x}))^2$$

则集成的 “分歧” 为

$$\begin{aligned}\bar{A}(h | \mathbf{x}) &= \sum_{i=1}^T w_i A(h_i | \mathbf{x}) \\ &= \sum_{i=1}^T w_i (h_i(\mathbf{x}) - H(\mathbf{x}))^2\end{aligned}$$

上式表示个体学习器在样本 x 上的不一致性, 即在一定程度上反映个体学习器的多样性

个体学习器 h 和集成 H 的平方误差分别为

$$E(h|\mathbf{x}) = (f(\mathbf{x}) - h(\mathbf{x}))^2$$

$$E(H|\mathbf{x}) = (f(\mathbf{x}) - H(\mathbf{x}))^2$$

令 $\bar{E}(h|\mathbf{x}) = \sum_{i=1}^T w_i \cdot E(h_i|\mathbf{x})$ 表示个体学习器误差的加权均值, 有

$$\begin{aligned}\bar{A}(h|\mathbf{x}) &= \sum_{i=1}^T w_i E(h_i|\mathbf{x}) - E(H|\mathbf{x}) \\ &= \bar{E}(h|\mathbf{x}) - E(H|\mathbf{x})\end{aligned}\tag{1}$$

式(1)对所有样本 $\mathbf{x}$ 均成立, 令 $p(\mathbf{x})$ 表示样本的概率密度, 则在所有样本上有

$$\sum_{i=1}^T w_i \int A(h_i|\mathbf{x}) p(\mathbf{x}) d\mathbf{x} = \sum_{i=1}^T w_i \int E(h_i|\mathbf{x}) p(\mathbf{x}) d\mathbf{x} - \int E(H|\mathbf{x}) p(\mathbf{x}) d\mathbf{x}\tag{2}$$

类似的, 个体学习器 h_i 在**全样本**上的泛化误差和分歧项分别为

$$\begin{aligned} E_i &= \int E(h_i | \mathbf{x}) p(\mathbf{x}) d\mathbf{x} \\ A_i &= \int A(h_i | \mathbf{x}) p(\mathbf{x}) d\mathbf{x} \end{aligned} \quad (3)$$

集成的泛化误差为

$$E = \int E(H | \mathbf{x}) p(\mathbf{x}) d\mathbf{x} \quad (4)$$

将式(3)、(4)代入式(2), 再令 $\bar{E} = \sum_{i=1}^T w_i E_i$ 表示个体学习器泛化误差的加权均值, $\bar{A} = \sum_{i=1}^T w_i A_i$ 表示个体学习器的加权分歧值, 有

$$E = \bar{E} - \bar{A} \quad (5)$$

式(5)表明: 个体学习器准确性越高、多样性越大, 则集成越好

多样性-多样性度量

多样性度量 (diversity measure) 是用于估算个体学习器的多样化程度

考虑个体分类器两两相似/不相似性, 给定数据集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$, 对二分类任务, $y_i \in \{-1, +1\}$, 分类器 h_i 与 h_j 的预测结果列联表 (contingency table) 为

	$h_i = +1$	$h_i = -1$
$h_j = +1$	a	c
$h_j = -1$	b	d

其中, a 表示 h_i 与 h_j 均预测为正类的样本数目; b 、 c 、 d 含义以此类推; $a + b + c + d = m$

	$h_i = +1$	$h_i = -1$
$h_j = +1$	a	c
$h_j = -1$	b	d

基于上述列联表，给出一些常见的多样性度量

- 不和度量

$$dis_{ij} = \frac{b+c}{m}$$

dis_{ij} 的值域为 $[0,1]$. 值越大则多样性越大

- Q-统计量

$$Q_{ij} = \frac{ad-bc}{ad+bc}$$

Q_{ij} 与相关系数 ρ_{ij} 的符号相同，且 $|Q_{ij}| \leq |\rho_{ij}|$

- 相关系数

$$\rho_{ij} = \frac{ad-bc}{\sqrt{(a+b)(a+c)(c+d)(b+d)}}$$

- k-统计量

$$\kappa = \frac{p_1 - p_2}{1 - p_2}$$

若分类器 h_i 与 h_j 在 D 上完全一致，则 $k=1$ ；
若仅是偶然达成一致，则 $k=0$

$$p_1 = \frac{a+d}{m}$$

$$p_2 = \frac{(a+b)(a+c) + (c+d)(b+d)}{m^2}$$

Sources

- <https://www.youtube.com/watch?v=LsK-xG1cLYA> AdaBoost, Clearly Explained 20mins
- <https://www.youtube.com/watch?v=WtWxOhhZWX0> Ensemble Learning | Simplilearn 35mins
- <https://www.youtube.com/watch?v=Un9zObFjBH0> Ensemble learners 3mins
- <https://www.youtube.com/watch?v=GM3CDQfQ4sw> Boosting 2mins
- https://www.youtube.com/watch?v=sVriC_Ys2cw Bagging example 1mins