

Lecture8

传统特征提取

目录

01 低维嵌入

02 主成分分析 (PCA)

03 核化线性降维


04 流形学习

05 度量学习

01 低维嵌入


低维嵌入

维数灾难 (curse of dimensionality)通常是指在涉及到向量的计算问题中，随着维数的增加，计算量呈**指数倍**增加的一种现象。




低维嵌入

- 缓解维数灾难的重要途径是降维(dimension reduction)
 - 即通过某种数学变换，将原始高维属性空间转变为一个低维“子空间”(subspace)，在子空间中样本密度大幅度提高，距离计算也变得更容易



低维嵌入——多维缩放（Multidimensional Scaling）

多维缩放即要求原始空间中样本之间的**距离**在低维空间中得以**保持**



低维嵌入——多维缩放（MDS）

假定： m 个样本在原始空间中的距离矩阵为 $D \in \mathbb{R}^{m \times m}$ ，其第 i 行 j 列的元素 $dist_{i,j}$ 为样本 i 到样本 j 的距离。

目标：使样本在 d 维空间中的欧氏距离等于原始空间中的距离，即 $\|z_i - z_j\| = dist_{i,j}$

令 $B = Z^T Z \in \mathbb{R}^{m \times m}$ ，其中 B 为降维后的内积矩阵， $b_{ij} = z_i^T z_j$ 有

$$\begin{aligned} dist_{ij}^2 &= \|\mathbf{z}_i\|^2 + \|\mathbf{z}_j\|^2 - 2\mathbf{z}_i^T \mathbf{z}_j \\ &= b_{ii} + b_{jj} - 2b_{ij} \end{aligned}$$

低维嵌入——多维缩放 (MDS)

为便于讨论，令降维后的样本表示 z 被**中心化**，即 $\sum_{i=1}^m z_i = 0$ 。显然，矩阵 $\mathbf{B}$ 的行与列之和均为零，即

$$\sum_{i=1}^m b_{i,j} = \sum_{j=1}^m b_{i,j} = 0$$

$$\text{则 } \sum_{i=1}^m \text{dist}_{ij}^2 = \text{tr}(\mathbf{B}) + mb_{jj}, \quad \sum_{j=1}^m \text{dist}_{ij}^2 = \text{tr}(\mathbf{B}) + mb_{ii}, \quad \sum_{i=1}^m \sum_{j=1}^m \text{dist}_{ij}^2 = 2m \text{tr}(\mathbf{B})$$

其中 $\text{tr}(\cdot)$ 表示**矩阵的迹 (trace)**， $\text{tr}(\mathbf{B}) = \sum_{i=1}^m \|z_i\|^2$ 。令

$$\text{dist}_i = \frac{1}{m} \sum_{j=1}^m \text{dist}_{ij}, \quad \text{dist}_{\cdot j} = \frac{1}{m} \sum_{i=1}^m \text{dist}_{ij}, \quad \text{dist}_{\cdot\cdot} = \frac{1}{m^2} \sum_{i=1}^m \sum_{j=1}^m \text{dist}_{ij}$$

低维嵌入——多维缩放（MDS）

输入：距离矩阵 $\mathbf{D} \in \mathbb{R}^{m \times m}$ ，其元素为样本到的距离 $dist_{i,j}$

低维空间维度 d'

过程：

1) 首先计算 $dist_{i.}$, $dist_{.j}$, $dist_{..}$

$$dist_{i.} = \frac{1}{m} \sum_{j=1}^m dist_{ij}, \quad dist_{.j} = \frac{1}{m} \sum_{i=1}^m dist_{ij}, \quad dist_{..} = \frac{1}{m^2} \sum_{i=1}^m \sum_{j=1}^m dist_{ij}$$

2) 计算矩阵 $\mathbf{B}$

$$b_{ij} = -\frac{1}{2} \left(dist_{ij}^2 - dist_{i.}^2 - dist_{.j}^2 + dist_{..}^2 \right)$$

3) 对矩阵 $\mathbf{B}$ 进行特征值分解

$\mathbf{B} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T$, 其中 $\mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_d)$ 为特征值构成的对角矩阵 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$, $\mathbf{V}$ 为特征向量矩阵

$$\mathbf{B} = \mathbf{V} \begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{pmatrix} \mathbf{V}' = \mathbf{V} \begin{pmatrix} \sqrt{\lambda_1} & & 0 \\ & \ddots & \\ 0 & & \sqrt{\lambda_n} \end{pmatrix} \underbrace{\begin{pmatrix} \sqrt{\lambda_1} & & 0 \\ & \ddots & \\ 0 & & \sqrt{\lambda_n} \end{pmatrix}}_{\mathbf{Z}} \mathbf{V}'$$

4) 取 $\mathbf{\Lambda}$ 为 d' 个最大特征值所构成的对角矩阵, $\mathbf{V}$ 为相应的特征向量矩阵

$$\mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_{d'})$$

输出: 矩阵 $\mathbf{Z} = \mathbf{V}\mathbf{\Lambda}^{1/2} \in \mathbb{R}^{m \times d'}$, 每一行是一个样本的低维坐标

02 主成分分析 (PCA)



主成分分析 (PCA)

□ 在特征向量正交的空间中，如存在一个超平面能较好地表示所有样本点，

则应具有如下两个性质：

- **最近重构性**：样本点到这个超平面的距离都足够近
- **最大可分性**：样本点在这个超平面上的投影尽可能分开

主成分分析 (PCA)




U_1 为主成分方向，因为当数据样本投影到 u_1 轴时满足最大可分性和最近重构性。

主成分分析 (PCA)

最大可分性

样本点 x_i 在新空间中超平面上的投影是 $\mathbf{W}^T x_i$. 若使所有样本点的投影尽可能分开, 则应使得投影后样本点的**方差最大化**。若投影后样本点的协方差是 $\sum_i \mathbf{W}^T x_i x_i^T \mathbf{W}$, 于是**优化目标**可写为

$$\begin{aligned} \min_{\mathbf{W}} \quad & \text{tr}(\mathbf{W}^T \mathbf{X} \mathbf{X}^T \mathbf{W}) \\ \text{s.t.} \quad & \mathbf{W}^T \mathbf{W} = \mathbf{I} \end{aligned}$$



主成分分析（PCA）

PCA求解

对上述优化式使用拉格朗日乘子法可得

$$\mathbf{X}\mathbf{X}^T \mathbf{w}_i = \lambda_i \mathbf{w}_i$$

只需对协方差矩阵 $\mathbf{X}\mathbf{X}^T$ 进行特征值分解，并将求得的特征值排序 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$ ，

再取前 d' 个特征值对应的特征向量构成 $\mathbf{W} = (\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_{d'})$ ，即获得降维后的数据表示。

主成分分析 (PCA)

PCA算法的具体步骤

输入：样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;
低维空间维数 d' .

过程：

- 1: 对所有样本进行中心化: $\mathbf{x}_i \leftarrow \mathbf{x}_i - \frac{1}{m} \sum_{i=1}^m \mathbf{x}_i$;
- 2: 计算样本的协方差矩阵 $\mathbf{X}\mathbf{X}^T$;
- 3: 对协方差矩阵 $\mathbf{X}\mathbf{X}^T$ 做特征值分解;
- 4: 取最大的 d' 个特征值所对应的特征向量 $\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_{d'}$.

输出：投影矩阵 $\mathbf{W} = (\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_{d'})$.

主成分分析（PCA）

例题：将X的维度从二维降到一维

$$\mathbf{X} = \begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix}$$

因为这个矩阵的每行已经是零均值，所以可以直接求协方差矩阵：

$$\mathbf{B} = \frac{1}{5} \begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix} \begin{pmatrix} -1 & -2 \\ -1 & 0 \\ 0 & 0 \\ 2 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} \frac{6}{5} & \frac{4}{5} \\ \frac{4}{5} & \frac{6}{5} \end{pmatrix}$$

求B的特征值和特征向量：

$$|A - \lambda E| = \begin{vmatrix} \frac{6}{5} - \lambda & \frac{4}{5} \\ \frac{4}{5} & \frac{6}{5} - \lambda \end{vmatrix} = \left(\frac{6}{5} - \lambda\right)^2 - \frac{16}{25} = (\lambda - 2)(\lambda - 2/5) = 0$$

求解得到特征值： $\lambda_1 = 2, \lambda_2 = 2/5$

对应的特征向量分别是： $\mathbf{b}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \mathbf{b}_2 = \begin{pmatrix} -1 \\ 1 \end{pmatrix}$

由于对应的特征向量分别是一个通解， $\mathbf{b}_1$ 和 $\mathbf{b}_2$ 可取任意实数

那么标准化后的特征向量为：

$$\begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}, \begin{pmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}$$


取最大的特征值对应的特征向量作为投影向量，可得到一维表示。

$$\begin{aligned} Y &= (1/\sqrt{2} \quad 1/\sqrt{2}) \begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix} \\ &= (-3/\sqrt{2} \quad -1/\sqrt{2} \quad 0 \quad 3/\sqrt{2} \quad -1/\sqrt{2}) \end{aligned}$$


03 核化线性降维

核化线性降维


- 线性降维方法假设从高维空间到低维空间的函数映射是**线性的**，但在很多实际任务中，线性映射不能很好地表达数据，需要使用**非线性映射**：



(a) 三维空间中的观察



(b) 本真二维结构




(c) PCA 降维结果

核化主成分分析(Kernelized PCA / KPCA)

考虑一个线性不可分的数据集，可使用映射 $\phi: R^2 \rightarrow R^3$ 将二维数据映射到三维空间，

取： $\phi([x_1, x_2]^T) = [x_1^2, x_2^2, \sqrt{2}x_1x_2]^T$ ，映射到高维空间后数据变得线性可分。



基于核技巧的线性降维方法 —— “核化” (kernelized)

核化主成分分析

假定将在高维特征空间中把数据投影到由 $\mathbf{W} = (\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_d)$ 确定的超平面上，即求解

$$\left(\sum_{i=1}^m \mathbf{z}_i \mathbf{z}_i^T \right) \mathbf{W} = \lambda \mathbf{W}$$

其中 $\mathbf{z}_i$ 是样本点 $\mathbf{x}_i$ 在高维特征空间中的投影表示；令 $\alpha_i = \frac{1}{\lambda} \mathbf{z}_i^T \mathbf{W}$ ，有：

$$\mathbf{W} = \frac{1}{\lambda} \left(\sum_{i=1}^m \mathbf{z}_i \mathbf{z}_i^T \right) \mathbf{W} = \sum_{i=1}^m \mathbf{z}_i \frac{\mathbf{z}_i^T \mathbf{W}}{\lambda} = \sum_{i=1}^m \mathbf{z}_i \alpha_i$$

核化主成分分析

假定 $\mathbf{z}_i$ 是由原始属性空间中的样本点 $\mathbf{x}_i$ 通过映射 ϕ 产生，即

$$\mathbf{z}_i = \phi(\mathbf{x}_i), i = 1, 2, \dots, m$$

若 ϕ 能被显式表达出来，则通过它将样本映射至高维空间，再在特征空间中做降维，可得

$$\left(\sum_{i=1}^m \phi(\mathbf{x}_i) \phi(\mathbf{x}_i)^T \right) \mathbf{W} = \lambda \mathbf{W}$$

并且

$$\mathbf{W} = \sum_{i=1}^m \phi(\mathbf{x}_i) \alpha_i$$

核化主成分分析

一般情形下，不清楚 ϕ 的具体形式，需引入核函数

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j).$$

将 $\mathbf{W} = \sum_{i=1}^m \phi(\mathbf{x}_i) \alpha_i$ 代入优化式 $(\sum_{i=1}^m \phi(\mathbf{x}_i) \phi(\mathbf{x}_i)^T) \mathbf{W} = \lambda \mathbf{W}$ 可得

$$\mathbf{K} \mathbf{A} = \lambda \mathbf{A}$$


其中 $\mathbf{K}$ 为 κ 对应的核矩阵, $(\mathbf{K})_{ij} = \kappa(\mathbf{x}_i, \mathbf{x}_j)$, $\mathbf{A} = (\alpha_1; \alpha_2; \dots; \alpha_m)$

上式为特征值分解问题，取 $\mathbf{K}$ 最大的 d' 个特征值对应的特征向量得到解。

核化主成分分析

对新样本 $\mathbf{x}$ ，其**投影后**的第 j ($j = 1, 2, \dots, d'$)维坐标为

$$\begin{aligned} z_j &= \mathbf{w}_j^T \phi(\mathbf{x}) = \sum_{i=1}^m \alpha_i^j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) \\ &= \sum_{i=1}^m \alpha_i^j \kappa(\mathbf{x}_i, \mathbf{x}) \end{aligned}$$



其中 α_i 已经过规范化， α_i^j 是 α_i 的第 j 个分量。由该式可知，为获得投影后的坐标，KPCA需对**所有样本求和**，计算开销较大。

04 流形学习

流形学习


- 流形学习(manifold learning) 借鉴了拓扑流形概念，“**流形**”是在局部与欧氏空间同胚的空间，在局部具有欧氏空间的性质，能用欧氏距离来进行距离计算。
- 当维数被降至二维或三维时，能对数据进行可视化展示，因此流形学习常用于可视化。



流形学习—等度量映射(Isometric Mapping)

在高维空间中计算直线距离具有**误导性**，因为高维空间的直线距离在低维嵌入流形上不可达


低维嵌入流形上两点间的本真距离是“**测地线**” (geodesic)距离



测地线距离与高维直线距离

流形学习—等度量映射(Isometric Mapping)

- 测地线距离的计算：对每个点基于欧氏距离找出其近邻点，建立一个近邻连接图，只有近邻点之间存在连接；将计算两点之间测地线距离转变为计算近邻连接图上的最短路径问题。
- 最短路径的计算可通过Dijkstra算法或Floyd算法实现；得到距离后通过多维缩放方法获得样本点在低维空间中的坐标。



测地线距离与近邻距离

流形学习—等度量映射(Isometric Mapping)

具体步骤:

输入: 样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;

近邻参数 k ;

低维空间维数 d' .

过程:

1: **for** $i = 1, 2, \dots, m$ **do**

2: 确定 $\mathbf{x}_i$ 的 k 近邻;

3: $\mathbf{x}_i$ 与 k 近邻点之间的距离设置为欧氏距离, 与其他点的距离设置为无穷大;

4: **end for**

5: 调用最短路径算法计算任意两样本点之间的距离 $\text{dist}(\mathbf{x}_i, \mathbf{x}_j)$;


6: 将 $\text{dist}(\mathbf{x}_i, \mathbf{x}_j)$ 作为 MDS 算法的输入;

7: **return** MDS 算法的输出

输出: 样本集 D 在低维空间的投影 $Z = \{\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_m\}$.

流形学习—局部线性嵌入(Locally Linear Embedding)

局部线性嵌入试图保持邻域内的线性关系，并使得该线性关系在降维后的空间中继续保持。




$$x_i = w_{ij}x_j + w_{ik}x_k + w_{il}x_l$$

流形学习——局部线性嵌入

算法步骤：

- 1) 求样本的 k 近邻，使用KNN算法；
- 2) 对每个样本求它在邻域里的 k 个近邻的线性关系，得到线性关系权重系数 W ；
- 3) 利用权重系数在低维空间重构样本数据。



具体过程如下：

输入：样本集 $D = \{x_1, x_2, \dots, x_m\}$ ，最近邻数 k ，低维空间维度 d

输出：低维样本集矩阵 D'

- 1) 使用欧式距离作为度量，计算和 x_i 最近的 k 个最近邻 $\{x_{i1}, x_{i2}, \dots, x_{ik}\}$ ；
- 2) 求局部协方差矩阵 $Z_i = (x_i - x_j)(x_i - x_j)^T$ ，并求出对应的权重系数向量：

$$\mathbf{W}_i = \frac{Z_i^{-1} \mathbf{1}_k}{\mathbf{1}_k^T Z_i^{-1} \mathbf{1}_k}$$

其中 $\mathbf{1}_k$ 为 k 维全1向量；

3) 由权重系数向量 $\mathbf{W}_i$ 组成权重系数矩阵 $\mathbf{W}$, 计算矩阵:

$$\mathbf{M} = (\mathbf{I} - \mathbf{W})(\mathbf{I} - \mathbf{W})^T$$


4) 计算矩阵 $\mathbf{M}$ 的前 $d + 1$ 个特征值, 并计算这 $d + 1$ 个特征值对应的特征向量:

$$\{\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_{d+1}\}$$


5) 由第2个特征向量到第 $d + 1$ 个特征向量所组成的矩阵即为低维样本矩阵:

$$\mathbf{D}' = (\mathbf{y}_2, \mathbf{y}_3, \dots, \mathbf{y}_{d+1})$$


Original Data




Regular LLE



Hessian LLE




ISOMAP



04 度量学习


度量学习

度量学习（Metric Learning）本质为空间映射方法，希望将数据样本映射到嵌入空间中使得相似样本的特征嵌入向量的距离小，不相似样本嵌入向量的距离大







① dissimilar ②



③ similar ④




相似图片 凳子




(1) Original Data Space

metric learning



(2) Metric Space

metric learning



(3) Final Metric Space



度量学习

对两个 d 维样本 x_1 和 x_2 ，欧氏距离为：

$$\text{dist}_{ed}^2(\mathbf{x}_i, \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_2^2 = \text{dist}_{ij,1}^2 + \text{dist}_{ij,2}^2 + \cdots + \text{dist}_{ij,d}^2$$

其中 $\text{dist}_{ij,k}$ 表示 x_i 与 x_j 在第 k 维上的距离；若不同属性的重要性不同，可引入属性权重 $\mathbf{W}$ ：

$$\begin{aligned}\text{dist}_{mah}^2(\mathbf{x}_i, \mathbf{x}_j) &= \|\mathbf{x}_i - \mathbf{x}_j\|_2^2 = w_1 \cdot \text{dist}_{ij,1}^2 + w_2 \cdot \text{dist}_{ij,2}^2 + \cdots + w_d \cdot \text{dist}_{ij,d}^2 \\ &= (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{W} (\mathbf{x}_i - \mathbf{x}_j)\end{aligned}$$

其中 $w_i \geq 0$, $\mathbf{W} = \text{diag}(w)$ 是对角矩阵

度量学习

W 的非对角元素均为零，即属性正交无关，但实际难以保证；为此将 W 替换为半正定对称矩阵 M ，得到马氏距离：

$$\text{dist}_{\text{mah}}^2(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i - \mathbf{x}_j)^T \mathbf{M} (\mathbf{x}_i - \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_{\mathbf{M}}^2,$$

其中 M 亦称“度量矩阵”，度量学习即对 M 进行学习；须满足有正交基 P 使得 $M = PP^T$ 。

Sources

- https://www.youtube.com/watch?v=AU_hBML2H1c
- Feature Extraction & Selection 5mins
- <https://www.youtube.com/watch?v=pr5LXi4U10c>
- Feature selection vs feature extraction 3mins
- <https://www.youtube.com/watch?v=lv8-YgWYtU4>
- Feature Extraction in 2D color Images 6mins
- <https://www.youtube.com/watch?v=AAs2yCa7G14>
- How to extract features from image using Python 5mins
- <https://www.youtube.com/watch?v=8A-W1xk7qs8>
- <https://www.youtube.com/watch?v=8QLlz-NvfxA>